國立臺灣師範大學 資訊工程學系

114 資訊專題研究（二）期末書面報告

AI 文字生成提示詞自動優化之研究

A Study on Automatic Prompt Optimization for AI Text Generation

指導教授 葉梅珍 教授

學生 黃繹軒 撰

中華民國 115 年 06 月

摘要

本專題旨在探討如何自動化的優化提示詞指令，以提升大型語言模型(LLM)的文字生成品質。本研究核心是利用元提示(Meta-Prompting)技術實作一個提示詞自動優化系統，整合角色扮演(Role-Play)、結構化(Structured)、思維鏈(CoT)與混合(Hybrid)等四種不同優化策略改寫提示詞。為了客觀驗證優化成效，本研究選定生活規劃、知識解說、寫作與疑問解答等四種任務類別模擬一般使用者的日常使用情境進行交叉測試，原始與優化後的提示詞會透過同個模型產生兩個獨立的輸出結果，並通過由三位異質模型組成的「AI 評審團」針對不同的輸出結果依據內容完整度、需求符合度、結構清晰度、創意與洞察力及語氣風格等五個維度進行一至十分的量化評分與具體評語，最後綜合評選出一個評分較高、較優秀的版本，若優化退化，則會觸發基於負反饋之閉環迭代優化機制。實驗結果顯示，經優化之提示詞在評估指標上整體皆有提升，顯示本系統能有效降低使用者與大型語言模型互動的門檻，並提升生成回應之整體品質。此外，也驗證了 Token 消耗數與整體提升量幾乎呈零相關，以及分析出各策略之間的成本-效益並找出黃金效益區間。本研究之範疇僅聚焦於大型語言模型之文字生成任務，不包含圖像、音樂或影片等多媒體生成之提示詞優化。

關鍵字：大型語言模型、元提示、提示工程、AI 評審、推論經濟學

目錄

摘要.....I

一、研究動機與研究問題.....1

二、文獻回顧與探討.....1

三、研究方法及步驟.....3

四、研究結果.....9

五、分析與討論.....14

六、結論及未來研究方向.....16

七、組員貢獻.....17

八、參考文獻.....17

一、 研究動機與研究問題

隨著大型語言模型(LLM)的快速發展，人機協作已演變為現代資訊社會之重要趨勢，大至內容創作、報告撰寫，小至資訊查詢與問題解答等，皆展現出廣泛的應用潛力，進一步帶動了「提示工程」(Prompt Engineering)此一新興技術領域的興起。然而，對於大多數日常使用者而言，精準設計高效的提示詞(Prompt)存在一定的學習成本與技術門檻。並且由於缺乏對提示詞的深刻理解，一般人在與 LLM 互動時，輸出品質往往呈現高度的隨機性與變異數，時而產出邏輯清晰、流暢的回應；時而給出膚淺、空洞的回覆內容，甚至給出錯誤資訊或出現幻覺。此種答覆品質不穩定之現象，並非源自模型先天的預訓練品質缺陷，而主要取決於輸入指令之構建策略與提問方式之落差。

儘管現有文獻已提出如角色扮演、思維鏈及結構化等多樣化優化技巧，但對於一般使用者而言，手動反覆測試與修改提示詞存在試錯成本。因此，若能建構一個系統，讓使用者僅需輸入提示詞並選定特定策略，即可透過預設之元提示詞模板引導模型進行自動化改寫，將能顯著降低人機互動門檻並提升協作效率。現有的研究多集中於單一且具高度確定性的邏輯推理或數學運算任務，缺乏對生活化之應用場景進行系統性的策略適用性分析。此外，混用多種優化策略是否在不同生成情境下均優於單一策略，現仍缺乏足夠的實證分析。

基於上述背景，本研究旨在透過工程實作與資料科學分析，探討並分析以下核心研究問題。首先，本研究期望實作基於元提示技術的提示詞自動優化系統，使用者能從四種優化策略中選擇其一對其輸入的提示詞進行優化，當中包含強調情境帶入的「角色扮演」、著重資訊組織的「結構化」、引導邏輯推演的「思維鏈」，以及整合上述特性的「混合策略」。其次，為驗證各優化策略的品質提升成效，本研究預計針對生活規劃、知識解說、寫作與疑問解答等四種涵蓋感性創作與理性回應的日常任務類型進行交叉測試，並由多個異質模型組成的「AI 評審團」進行多面向、客觀的評比分析。透過分析評審團所做的評分與回饋，預計量化出各優化策略與測試任務類別的適配度、探討混合策略與單一策略之間的優化效益差異，換句話說，實證「奧卡姆剃刀原則」：在不同情境下是否能以較簡潔的優化策略就達到理想的生成品質。並且，本研究更進一步分析各優化策略之品質提升量與系統營運成本之間的相關性，用以探明 LLM 自動優化之經濟效益。

二、 文獻回顧與探討

本章節將針對與本研究相關之學術文獻進行探討，藉此建構自動化提示詞優化系統與成本效益計量分析之理論根基。內文將分為五個核心部分：首先，回顧提示工程領域之興起；其次，分析本系統所採用的關鍵優化策略，包括角色扮演、結構化設計及思維鏈等，並探討其理論基礎；第三，探討以大型語言模型作為優化器之自動化改寫機制；第四，檢視大型語言模型評審機制的可行性與多模型審查架構；最後，探討大型語言模型之推論經濟學研究。

2.1 提示工程之興起

隨著預訓練語言模型的參數規模迅速增長，自然語言處理的研究範式逐步從以任務為主的模型微調，轉向重視模型上下文學習能力的提示導向方法。Sahoo 等人[1]在其對提示工程的系統性調查中指出，相較於傳統的「預訓練—微調」流程，提示導向的「預訓練—提示—

預測」範式在計算成本和應用彈性方面更具有優勢，且能有效激發零樣本與少樣本之泛化能力。該研究強調，提示工程的關鍵在於如何透過精準的指令設計、上下文示例構建與推理路徑引導，最大化調用大型語言模型在特定下游任務中的潛在效能。

2.2 提示詞優化策略之探究

「角色扮演」提示策略被證實能提升模型在特定領域知識調用的準確性。Kong 等人的研究表明[2]，當提示詞賦予模型明確的專家身分時，能構建出一種「社會模擬」情境，藉此限縮模型的知識邊界並模擬特定角色的語氣風格，進而在零樣本推理任務上展現出顯著優於常規指令的表現。

「結構化提示」為針對模型輸出格式混亂且難以解析的問題。Reynolds 與 McDonell[3]提出了「提示程式設計」的概念，他們主張提示詞不應僅被視為自然語言敘述，而應被視為一種對模型的「功能定義」。該研究證實，透過在提示詞中施加明確的格式約束、標籤化區塊與任務規格說明，能有效收斂模型的生成空間，使其產出邏輯與結構更為嚴謹的內容。

「思維鏈」主要針對邏輯複雜度較高的推理型任務。Wei 等人發表之研究顯示[4]，透過在提示詞中顯式引導模型生成「中間推理步驟」，能有效激發模型的邏輯推演潛能，藉由「先解釋推理、後給出結論」的機制，從而大幅降低幻覺發生率並提升答案的精準度。該研究顯示，此策略在 GSM8K 基準測試中取得了突破性進展，準確率相比原始提示詞得到了大幅提升。

2.3 自動化優化提示詞

傳統的人工提示詞設計存在高度試錯成本且重度依賴使用者直覺與經驗，因此，利用 LLM 本身的能力來優化提示詞已成為前沿研究方向。

Zhou 等人[5]提出了自動提示工程(APE)的框架，將提示詞生成視為一種「程式合成」問題，展示了 LLM 具備根據輸入輸出範例自我篩選並生成優於人類手寫指令之潛力。在此基礎上，Yang 等人[6]進一步提出了 OPRO 架構，將 LLM 視為優化器。該架構利用元提示引導模型根據過往的優化軌跡與評分回饋，迭代生成分數更高的新提示詞。本研究實作之自動優化核心機制即深受此架構啟發，採用元提示詞模板引導核心優化器執行指令之自動改寫。

2.4 基於大型語言模型之評估

在生成式任務中，如何客觀且低成本地評估輸出品質是一大挑戰。Zheng 等人[7]在其研究深入探討了使用強大的 LLM 作為評審的可行性。透過 MT-Bench 基準測試，該研究證實了高階模型在執行兩兩對比評分時，與人類專家的評分呈現高度一致性，且提供之評語具可解釋性。然而，Wang 等人[8]則指出，單一的 LLM 評審在實務上存在不可忽視的系統性偏誤，包含受文本呈現順序干擾的「位置偏誤」與盲目給予長文本高分的「字數偏誤」等。

為了修正單一模型評審所導致的評估公信力不足，Chan 等人[9]提出了多模型協同評估的 ChatEval 框架，實證透過不同參數量與不同訓練陣營之異質大模型組成「評審團」，能利用多代理人辯論與統計平均機制有效抵消單一模型的系統性盲點與偏好。基於上述驗證，本

研究採用異質多模型評審團架構及雙盲評分機制，以確保實驗數據之客觀性與可信度。

2.5 提示詞優化之成本效益與大型語言模型推論經濟學

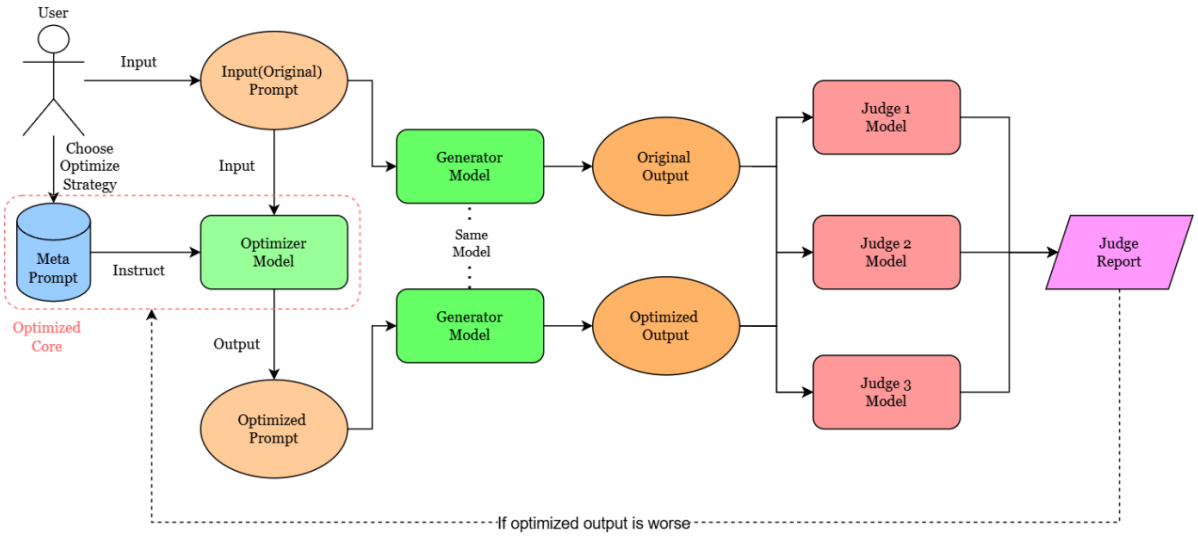
既有的自動化提示工程研究多追求品質指標之絕對提升，普遍忽略了工程收尾時所面臨的推論資源開銷。隨著 LLM 邁入大規模商業化部署階段，推論資源與生成品質之間的權衡尤為重要。Chen 等人[10]提出 FrugalGPT 理論，揭示了 LLM 推論中存在嚴重的邊際效益遞減與成本經濟學規律。該研究指出，提示詞隨著改寫機制盲目膨脹，會帶來嚴重的經濟悖論與推論延遲，而透過輕量化的策略調度，則能在大幅壓縮 Token 成本的同時，保有同等甚至更優之生成品質。以上為本研究所做的「成本效益相關性分析」提供了關鍵的理論支撐。

三、 研究方法及步驟

3.1 系統架構與流程

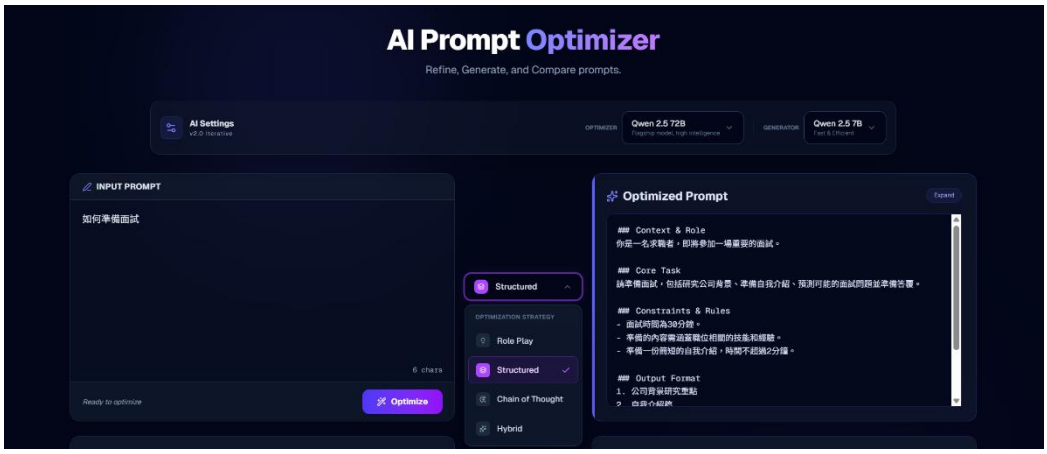
本研究實作之「提示詞自動優化系統」在工程架構上採用前後端分離設計，前端基於 Next.js 核心開發框架，並結合 Tailwind CSS 製作具美感且直觀的操控介面設計；後端則串接多個模型 API，透過模組化控制流執行協同運作。系統之核心運作流程如隔頁圖 1 所示，以下為步驟說明：

1. 使用者輸入：使用者輸入一個 prompt，並選擇四種優化策略之一。
2. 元提示優化：系統根據使用者所選擇的優化策略，依據該策略預設之元提示詞模板引導作為 Optimizer 的 LLM 對使用者輸入指令進行改寫，並輸出優化後的提示詞。(本研究的 Optimizer Model 選用 GPT-5.2)
3. 內容生成：為客觀對比優化成效，系統採用相同的生成模型作為對照基準，在完全相同的參數配置下，分別依據原始提示詞與優化提示詞生成「原始輸出」與「優化輸出」兩組獨立的文本結果。(本研究的 Generator Model 選用 GPT-4o-mini)
4. 評分報告：接著將兩組生成內容以隨機順序一併送至後端的 AI 評審團進行多面向的雙盲量化評估，並產出各評審之評議分數與具體評語，最終分數為三者之平均。(本研究的評審團 Model 共三位，分別為 GPT-5、Gemini-3.1-Flash-lite 及 Llama-3.3-70b-versatile)
5. 迭代優化：若評審團判定優化後的輸出品質出現倒退現象(即平均優化分數低於平均原始分數)，系統將自動觸發新一輪的指令迭代優化。系統會將評審團做出的弱點缺陷修正建議作為負反饋重新送回元提示優化核心，迫使優化器模型進行再次迭代。為防止系統在面對極度刁鑽或含糊的提示詞時陷入推論的無窮迴圈，後端設有最大迭代次數(實驗設定為 2 次)作為工程保險絲，當迭代優化表現超越原始結果或達到臨界次數時，系統即停止運作，並動態累計歷次改寫與生成過程中所消耗之推論 Token 總量計為營運總成本，且採用最終輸出之完整 AI 評議報告作為該筆實驗提示詞之數據紀錄。



(圖 1：系統流程圖)

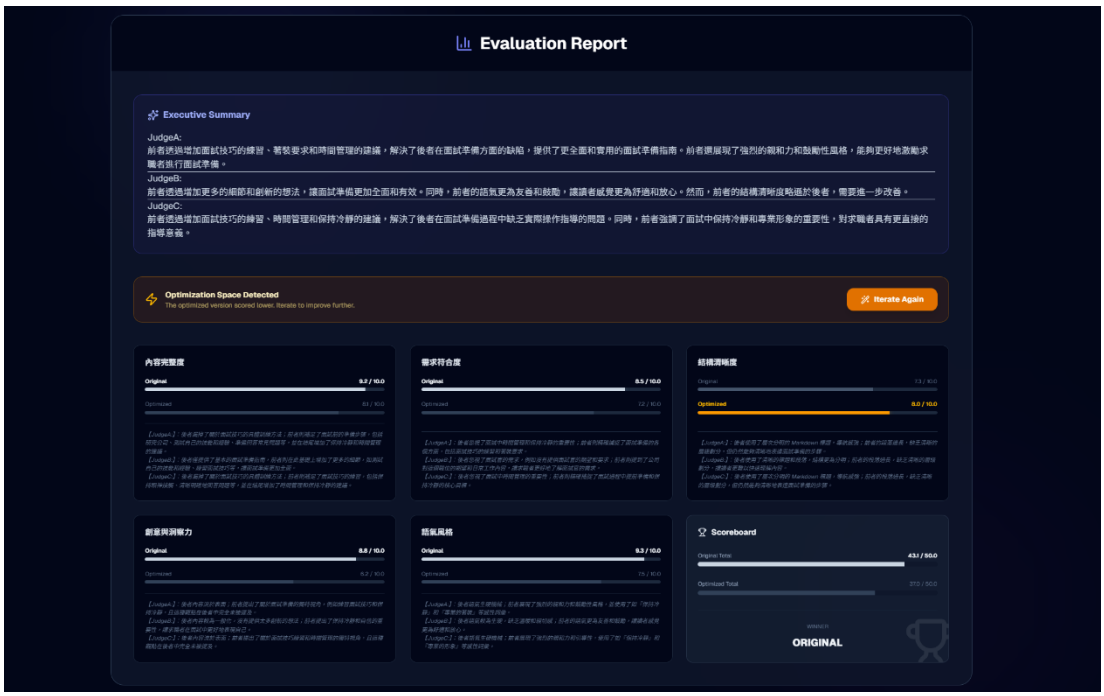
以下圖 2、圖 3 及圖 4 為實際系統畫面，但畫面中的測試內容僅供參考，與本實驗無關。



(圖 2：上方 Settings 可選優化與生成器，左側為使用者提示詞輸入框，中間可選擇優化策略)



(圖 3：提示詞的輸出結果採並排顯示，左側為原始指令，右側則為優化指令的文本輸出)



(圖 4：評審團之評議報告，每位評審都會針對不同面向評分與下評語，也會做整體評語，報告中的分數為三者之平均，若原始提示詞分數較高，則可進行迭代優化(如圖中黃色按鈕))

上述為實際系統之介面與運作流程，在實驗中若出現可進行迭代優化的情況會直接進行。

3.2 提示詞優化策略設計

本研究依據既有文獻之理論基礎，設計了以下四種元提示詞優化策略模板：

1. 角色扮演(Role-play)：旨在強化情境帶入感與專業語氣。元提示詞首先指示優化器分析輸入內容的潛在領域，並據此自動賦予一個最適配的權威專家身分。接著，優化器會依循規範，模擬該專家的思考模式、專業術語與語氣風格，將使用者的模糊需求轉化為該領域的具體指派任務，最終輸出包含角色設定與任務內容等的優化提示詞。以下為「角色扮演」策略之元提示詞內容：

“

STRATEGY: Persona-Driven Optimization.

Rewriting focus: Analyze the potential domains of user input and assign the most suitable expert identities ("You are...") and immerse the task in professional domain-specific terminology.

”

2. 結構化(Structured)：此策略主要用於解決模型輸出格式發散且難以解析之問題。元提示詞指示優化器將使用者的原始輸入進行解構，並重新組織為「情境與角色」、「核心任務」、「限制與規則」及「輸出格式」等獨立且標籤化的模組，最終將各模組與其對應的格式約束、任務說明整合為完整的優化提示詞。此機制旨在透過模組化的指令架構消除語意歧義，確保最終生成的內容嚴格遵守規範。以下為「結構化」策略之元提示詞內容：

”

STRATEGY: Structured Component Prompting.

Rewriting focus: Decompose the user input into [Context & Role], [Core Task], [Constraints & Rules], [Output Format], and [Style & Tone]. Use clear headers.

”

3. 思維鏈(CoT)：針對邏輯複雜度較高的任務進行推理引導。透過元提示詞指示優化器在優化過程中，強制嵌入「逐步思考」的指令進新生成的提示詞中。優化提示詞會明確規範模型在產出最終答案前，必須先擬定詳細的推理計畫，並依序展示分析步驟與推導過程。藉由引導模型執行這種「先解釋推理、後給出結論」的機制，強制其進行邏輯驗證，從而大幅降低幻覺並提升答案精準度。以下為「思維鏈」策略之元提示詞內容：

“

STRATEGY: Chain of Thought (CoT).

Rewriting focus: Force the AI to "Think step-by-step" and outline specific logical reasoning phases before providing the final answer.

”

4. 混合(Hybrid)：該策略為以上三種優化策略之集大成者，旨在驗證多重策略疊加後的綜合效果。在元提示的引導下，優化器會先賦予原提示詞合適的權威專家角色以確立專業語氣，接著透過標籤化的區塊嚴格定義任務背景與限制條件，最後嵌入強制性的逐步推理指令以確保邏輯正確性。此策略旨在同時兼顧內容的專業深度、格式的易讀性與邏輯的嚴密性。以下為「混合」策略之元提示詞內容：

“

STRATEGY: Hybrid Optimization.

Rewriting focus: Dynamically synthesize multi-dimensional prompt frameworks. You must integrate professional identity, explicit structural constraints, and systematic reasoning pathways into a cohesive instructions set. Please rewrite the user input according to the following integrated framework:

1. [Expert Persona & Tone]:
   - Define the most authoritative expert identity ("You are...") suitable for the task.
   - Establish a professional, domain-specific terminology and tone.
2. [Structured Execution & Constraints]:
   - Decompose the task into clear operational components: [Context], [Core Objective], [Strict Rules & Guardrails].
   - Define the precise [Output Format] (e.g., Markdown, specific headers, or JSON) to ensure

scannability.
3. [Cognitive Reasoning Pathway (CoT)]:
- Explicitly embed a step-by-step thinking mandate ("Think step-by-step").
- Define the precise logical sequence the AI must process (e.g., Analysis -> Evaluation -> Synthesis) before delivering the final output.
4. [Adaptability Balancing]:
- Ensure the prompt maintains high contextual flexibility while upholding rigid logical boundaries.

”

每種優化策略都共有的元提示詞如下:

“

You are a world-class Prompt Engineer. Your mission is to rewrite the user's prompt to achieve maximum effectiveness.

CRITICAL CONSTRAINTS (Must Follow):
1. Strict Output Isolation: Return ONLY the final optimized prompt text.
2. Language Requirement: Reply using the language that the user primarily uses.
3. No Placeholders: Output must be ready-to-use.

CRITICAL: DO NOT introduce new requirements not in Original User Intent.
- You may refine wording, clarify ambiguous instructions, or reorganize.
- DO NOT add new demands that change the user's intent.

”

3.3 測試資料集與情境

為確保實驗數據具備真實性與多樣性，本研究之測試資料集取自 LMSYS-CHAT-1M 公開資料庫。該資料庫收錄了百萬筆真實使用者與大型語言模型的對話紀錄，廣泛涵蓋了各種提問意圖與語言風格。

本研究從此資料庫隨機抽取使用者輸入之 prompt，並標註不同對應任務類別。本實驗主要分析以下四種類別的提示詞，每種任務類型各安排 25 筆 prompt 進行測試，總計 100 筆測試資料。

1. 生活規劃(Life Planning)：涉及行程安排、飲食計劃、購物清單等具備明確限制條件之任務。
2. 知識解說(Knowledge Explanation)：涵蓋科學原理、歷史事件或名詞解釋等，強調資訊正確性與解釋清晰度的任務。
3. 寫作(Writing)：包含文案撰寫、郵件擬稿、創意故事等，主觀性強且強調語氣、創

意與情感共鳴等的任務。

4. 疑問解答(Q&A)：涉及邏輯糾錯、具體問題回答等，強調邏輯嚴密性與答案精準度的任務。

3.4 多模型評審團與量化評估機制

為了消除單一大型語言模型作為評審時所無法避免的「自我模型偏好」與「字數偏誤」等系統性盲點，本研究實作了異質多模型的「AI 評審團」架構，分別為 GPT-5、Gemini-3.1-Flash-lite 及 Llama-3.3-70b-versatile。

在評估過程中，系統採用嚴格的雙盲審查機制，將原始輸出與優化輸出以隨機順序一併送至三位 AI 評審中。三位評審會獨立針對以下五大核心維度進行 1 至 10 分的客觀量化評分(10 分最佳)並給出具可解釋性的具體評語：

1. 內容完整度(Completeness)：評估內容是否涵蓋了主題的所有關鍵面向，以及論述的深度是否充足。

2. 符合需求度(Requirement)：評估內容是否遵守提示詞的顯性約束，以及是否貼合使用者的原始輸入。

3. 結構清晰度(Structure)：評估內容邏輯是否連貫，與段落層次是否清晰等。

4. 創意與洞察力(Creativity)：評估內容是否提供了獨特的觀點或較深度的觀察。

5. 語氣風格(Tone & Style)：評估文字的語氣是否具有感染力，以及是否融入當下情境的上下文。

最終，系統後端會自動統整三位異質評審在各個維度上的評分，並透過統計平均的方式計算出最終的量化分數，以此消除單一模型的偏好與潛在評估偏誤，從而確保整個自動優化系統實驗數據之客觀性與可信度。

3.5 迭代優化機制

為了賦予自動化提示工程動態自我修正之能力，本研究在評估流程中實作了基於負反饋的閉環迭代優化機制，打破傳統提示詞改寫僅依賴單次生成的開放式架構。當 AI 評審團執行完雙盲審查並結算分數後，若系統偵測到優化後文本之綜合評分低於原始提示詞文本之評分，即判定發生優化退化，後端控制流將啟動迭代優化。此機制整合三位異質評審委員所給出之具體缺陷評語，建構出結構化之「錯誤修正軌跡」，並連同原始提示詞、前一輪失敗的優化指令一同重新注入優化器模型中，引導其針對失焦或結構鬆散等缺點進行再次優化。

在收斂條件與工程安全性的設計上，本系統採用兩種終止邏輯以兼顧品質下限與推論經濟效益。系統之理想收斂條件為優化總分超越原始提示詞總分，此時判定為優化成功並終止；再者，為了防範黑盒子模型在面對刁鑽或模糊輸入時陷入無窮迴圈，系統設置最大迭代次數限制(實驗設定為 2 次)作為工程保險絲，一旦達到臨界次數便終止迭代優化。換言之，若優化提示詞總分連續小於原始提示詞總分三次即判定為優化失敗。此實驗架構在數據統計

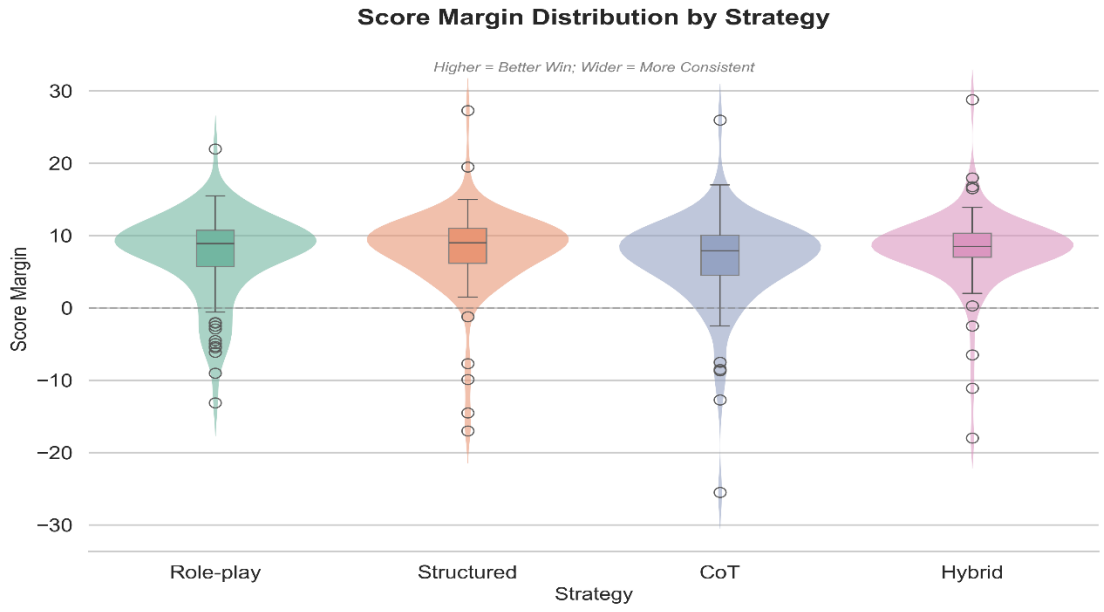
上採用終局結算的累計邏輯，不拆分中間過程點，而是將歷次改寫與生成過程中所耗費之推論 Token 總量動態加總，計為該筆實驗提示詞之總成本(Total Operational Token Cost)，以此作為後續統計分析之核心數據基礎。

四、 研究結果

本章節將基於實驗之量化數據，依據「總體品質增益」、「多維度品質指標」、「情境與成本雙軸交叉」、「系統成本相關性計量」、「系統有效性邊界」以及「策略之成本效益象限」之邏輯順序，系統性地剖析四大元提示優化策略之實驗結果，藉此探明大型語言模型在自動提示工程中的性能特徵與營運經濟效益。

4.1 整體優化成效分佈

為驗證本優化系統的整體穩定性與有效性，本研究統計了四種策略在所有測試樣本中的「勝分差(Score Margin)」分佈，如下圖 5 所示。Y 軸代表優化提示詞生成文本與原始提示詞生成文本之總分差值，數值大於 0 代表優化有效。

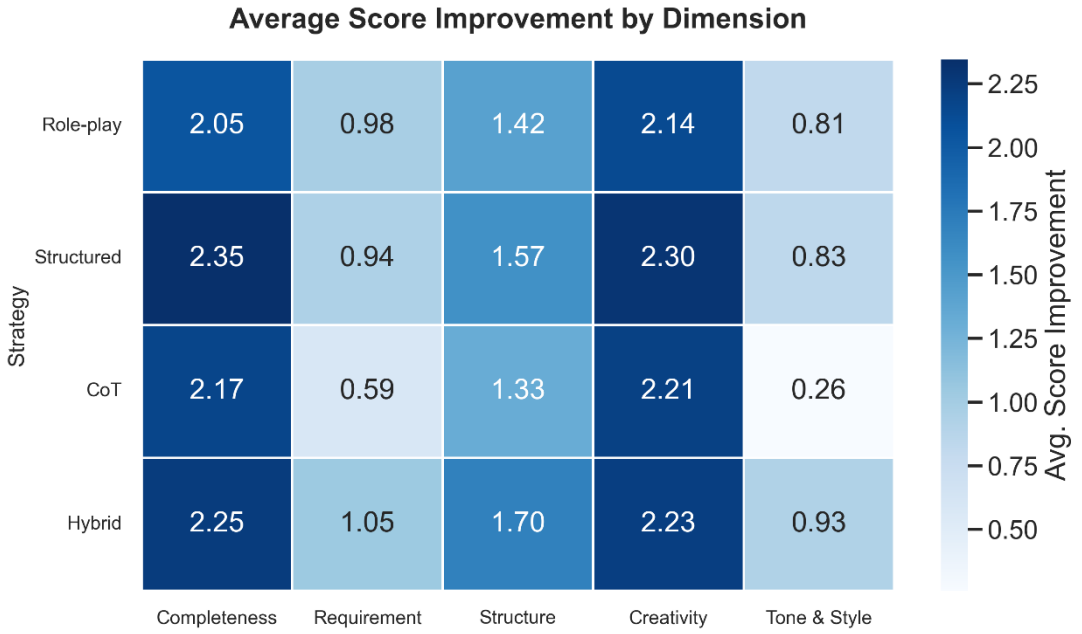


(圖 5：四種優化策略之勝分差分佈小提琴圖)

從上圖 5 可以觀察到以下趨勢：四種優化策略的分數分佈主體(小提琴圖的寬廣區域)均顯著高於 0 分基準線，且中位數多接近正 10 分區間，證實本系統能有效提升提示詞生成品質。然而，各策略之幾何邊緣與異常值分佈反映出顯著的策略穩定性差異。結構化(Structured)與混合策略(Hybrid)的圖形呈現較寬且底部較細的型態，顯示其優化效果最為穩定，鮮少出現負分情況，展現極高的性能下限。思維鏈(CoT)的圖形細長且下方存在顯著的負分異常值(Outliers)，部分樣本分數甚至跌至負 25 分。這顯示思維鏈雖然平均表現尚可，但變異數極大，在特定情境下存在導致生成品質嚴重倒退的風險。同時，角色扮演(Role-play)雖然整體表現優異，但明顯有多個負分異常值介於 0 至負 10 分之間，顯示此單一策略在面對非適配任務時可能反而導致生成品質變差。

4.2 多維度品質指標分析

為進一步剖析各優化策略對文本細項特徵之影響，下圖 6 展示了各策略在五大評分維度上的平均提升分數。

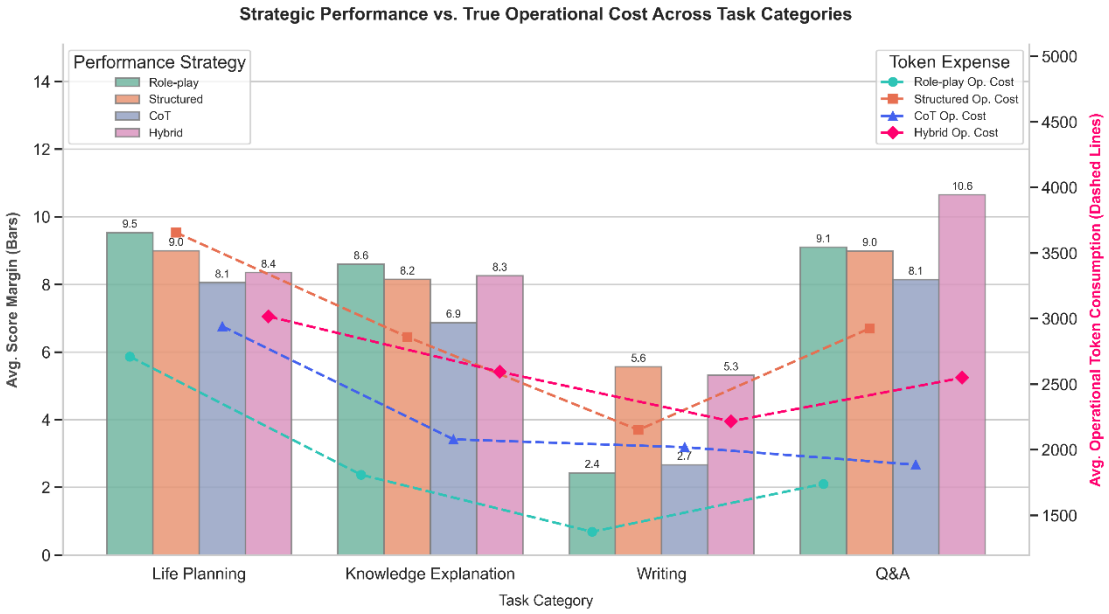


(圖 6：優化策略於各評分維度提升分數之熱力圖)

根據此熱力圖可歸納出各優化策略之優勢光譜：混合策略展現了最強的綜合提升能力，在五個維度皆位居前二名，甚至有三個維度為榜首，證實多技巧疊加對於文本綜合表現為正回饋；結構化策略在「內容完整度」及「創意與洞察力」兩維度皆位居榜首，打破了框架限制會扼殺模型創意之直覺；角色扮演策略在五個面向皆有所提升，但優勢不明顯；思維鏈策略能使輸出內容更豐富並附有條理，但容易導致偏題，且對文字輸出風格幾乎沒有提升。

4.3 任務情境與推論成本之雙軸交叉分析

不同任務類別對優化策略之響應及伴隨之 Token 推論代價存在顯著之非線性落差，其多維度交叉比對如隔頁圖 7 所示。此圖表以長條圖代表平均勝分差，並引入虛折線對應右邊的次要 Y 軸，用以追蹤各策略在特定任務下所消耗之平均營運耗費 Token 總量。



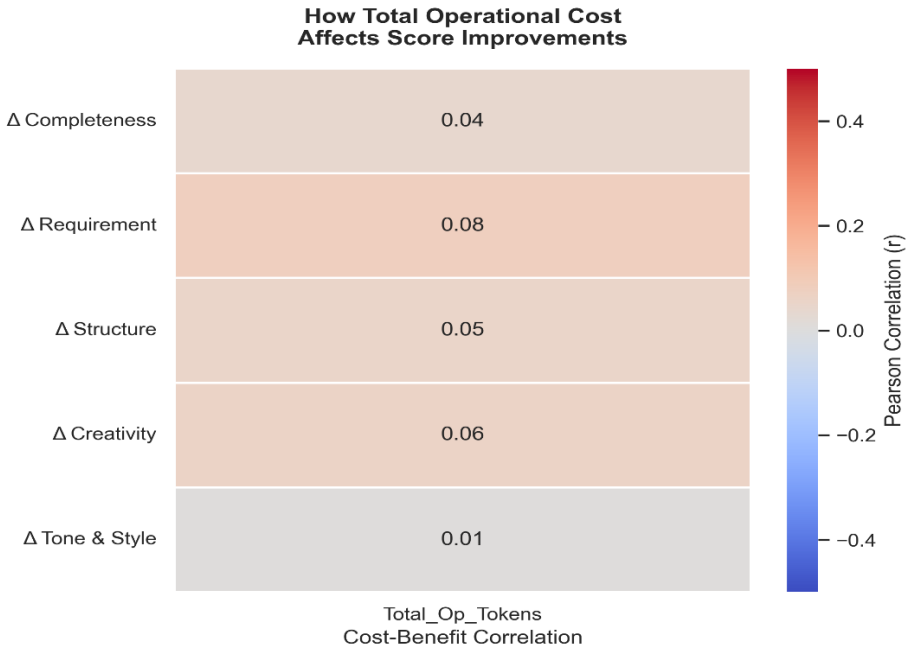
(圖 7：各任務類別之優化成效與推論成本雙軸圖)

上圖 7 數據顯示，在理性邏輯主導之「疑問解答(Q&A)」情境中，混合策略取得了全場最高之平均勝分差，顯著優於其他單一策略，但其代價為高昂之推論成本。而在「生活規劃(Life Planning)」與「知識解說(Knowledge Explanation)」任務中，角色扮演策略分別奪得 9.5 與 8.6 勝分之最優表現，且其對應之 Token 消耗均處於最低位，顯示專家身分之帶入能以最低之資源代價換取最精準之知識調用。

反觀主觀性極強之「寫作(Writing)」類別，所有策略之品質提升普遍陷入低谷，其中結構化策略雖獲得該情境最高之勝分差，但其伴隨之 Token 開銷急遽攀升，反映出生成模型在格式約束與感性創作之多目標優化中存在劇烈之資源拉鋸。思維鏈在寫作任務中之平均勝分差極低，且能耗表現高，進一步證實了邏輯推理框架在感性創作情境底下的低適配度。

4.4 系統營運成本之相關性計量分析

為了探明「指令與改寫字數越長，優化成效是否越好」，本研究引入皮爾森相關係數進行計量分析，如隔頁圖 8 所示。該熱力圖量化了真實營運總成本與五大品質維度提升淨值之間之線性相關程度。

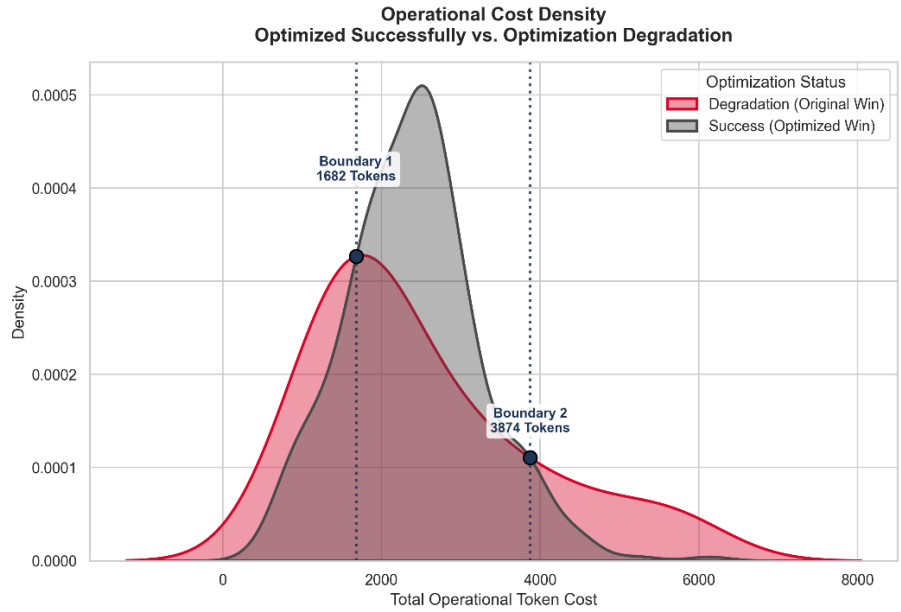


(圖 8：Token 消耗與評分維度提升之相關性熱力圖)

上圖 8 數據顯示，所有評分維度之相關係數均小於 0.1，可以說 Token 消耗量與每個維度的提升量幾乎都為零相關，證實了堆砌字數對提示詞之輸出文本品質不一定會帶來正反饋，為後續推論奧卡姆剃刀原則與輕量化調度策略提供了依據。

4.5 系統有效性邊界分析

在實證真實成本與品質幾乎成零相關後，本研究進一步利用無母數核密度估計(KDE)，探明此自動優化系統的機率分布特徵與失效臨界點，其診斷曲線如下圖 9 所示。藉由尋找優化成功群體與優化退化群體兩組分布，本研究首度精確定位出系統之雙重決策臨界邊界。



(圖 9：營運成本勝負之核密度估計圖)

上圖 9 數據顯示，Token 消耗數介於 1682 至 3874 為「黃金營運效益區間」，在此區間的優化成功機率較高，在 2500 附近達到極致。在此區間左側，可能因 Token 總長度不足、元提示規則展開不全，導致失敗機率密度高度隆起；而在此區間右側，成功曲線迅速收斂至地平線，而失敗曲線之尾巴卻自然延伸，可能為 Token 消耗較多時，系統因反覆觸發負反饋而陷入盲目過度迭代之惡性循環，或因生成文本過度冗長發散而誘發邊際效益遞減之退化狀態。

4.6 優化策略之成本效益象限分析

最後，本研究將四種優化策略之統計平均值投射至「成本-效益四象限」中，以進行宏觀的策略投資報酬率評估，其矩陣特徵如下圖 10 所示。圖表 X 軸代表平均推論 Token 消耗量，Y 軸代表平均勝分差。圖中虛線為平均值。



(圖 10：成本-效益象限分析圖)

由上圖可見，第二象限為最理想之區間，此區間代表該策略能以較低的 Token 消耗換取相對較佳的優化效果。位於第一象限之混合、結構化策略為以高能耗換取高效益之手段，當中，又以混合策略較好，因其為四者之中優化效果最佳者。相對地，角色扮演策略位於第三象限之左上方，其平均推論成本最低卻能達到約整體平均之優化效果。反觀思維鏈策略，其 Token 消耗不少，效益卻極低。此一完整的結果光譜顯示：在資源受限環境或特定情境下，選用單一且精簡的角色扮演策略，能在大幅壓縮 Token 成本的情況下保障高度理想的生成品質；反之，若不計成本只想取得最佳的優化性能，則使用混合策略為最佳的手段。

五、 分析與討論

本章節將基於前一章節之實驗結果進行深度分析與學術思辨。內文將分為五個核心部分展開：第一，剖析結構化引導機制對於創意生成任務所帶來之反直覺正向影響；其次，針對「寫作任務類別」優化效益低迷之現象進行剖析；第三，權衡混合策略在風險管控與高昂能耗之間的矛盾，探討其邊際效益遞減特徵；第四，論證大模型推論經濟學；第五，探討若換成較高階的生成模型是否會影響現有結果分析。

5.1 結構化引導對創意生成的反直覺影響

在傳統提示工程與人機協作之刻板認知中，一般多直覺地認為「過多的格式約束與框架限制會扼殺模型的發散思維與創意空間」，因此在面對主觀性極強、強調情感共鳴之任務類別時，實務上多傾向採用具備開放語境之角色扮演策略。然而，本研究數據推翻了此一傳統假設。實驗數據明確指出，在寫作任務中，結構化策略之平均勝分差 5.6 分顯著凌駕於角色扮演策略 2.4 分；且在多維度品質光譜之熱力圖中，結構化策略在「創意與洞察力」細項指標上更為全場最高之增益淨值。

本研究推測，導致此種反直覺現象之核心機制在於「認知負載的釋放」。LLM 在執行開放式文字生成時，其內置之注意力機制與推論資源必須同時分配予兩大目標，一方面為構思整篇文章之宏觀邏輯架構與段落銜接，另一方面則為填充具體內容之語意深度與切入點。當結構化策略透過元提示詞施加清晰之標籤化區塊與嚴謹格式約束時，實質上等同於在外部預先為模型建構了高強健度之骨架，從而完全免除了模型在「結構規劃」上的運算開銷，使其能將推論資源集中於內容生成的創意深度與新穎性。相反地，單純的角色扮演策略雖賦予了專家語氣，但因缺乏剛性的格式矩陣引導，模型在長文本解碼過程中極易陷入注意力發散與語意漂移之困境，導致內容發散、重點失焦，最終反倒削弱了創意的實質含金量 。

5.2 寫作任務類別優化效益低迷之分析

儘管系統在理性任務中表現優異，但對於「寫作任務」類別之優化成效卻陷入低谷。本研究推測是由於寫作任務的原始提示詞通常已賦予模型極高的發散空間，當優化器介入優化時，無論是強加結構矩陣還是思維鏈條，其本質上都是在語意空間中施加「高難度約束」。這種約束對於理性任務而言是降低隨機幻覺之「去噪」過程；但對於強調靈感與發散的感性創作任務而言，剛性的元提示規則反倒壓縮了模型進行隨機採樣之自由度，強行將模型限縮在標準化、機械化的生成路徑中。這種「優化規則與感性發散之間的代價拉鋸」，最終導致自動改寫機制在寫作情境中的品質增益顯著遞減。

5.3 混合策略之風險管控與邊際效益遞減特徵

混合策略作為多重提示技巧之集大成者，其在實驗中展現出極高的優化下限。由圖 5 可以清晰觀察到，混合策略之箱型最小、數據最集中，且在圖 6 之五個指標上皆表現卓越。這實證了混合策略之最大核心價值在於「極高之性能下限防禦力」與「全面之風險管控能力」。多策略的融會貫通使得模型在面對未知或需求不夠明確的任務時，具備強大的全局防禦手段，不易因單一規則失效而全面崩潰，因此可被定位為全系統最安全之「萬用優化手

段」。

然而，根據本研究引入之推論 Token 耗費計量，混合策略背後隱藏之「邊際效益遞減」特徵也因此顯現。由圖 7 之雙軸交叉分析圖可看出，混合策略只在 Q&A 中拔得頭籌，其餘任務類別之品質增益均落後於特定之單一策略，但其平均營運 Token 消耗卻在所有任務情境中皆穩居高位。這意味著混合策略試圖在一個提示詞內同時驅動專家身分、結構約束與逐步推理，極易導致指令語意空間之過度擁擠。模型在解碼時必須在多個複雜目標間執行高難度的注意力權衡，這不僅未能催化出線性加總的品質躍升，反而因指令規則間的潛在互斥而引發了推論能耗的嚴重浪費，展現出顯著的邊際效益飽和特徵。

5.4 論證大模型推論經濟學

上述品質與資源能耗之非線性特徵，在本研究進一步深入計量分析後，獲得了一些實證支持。圖 8 顯示，真實營運總成本與五大品質提升量之間的相關係數均小於 0.1，表示其幾乎都呈零相關。這也表示，在此系統之閉環迭代優化中，盲目堆砌指令字數與耗費額外的 Token，並不能保證輸出文本品質的線性正向提升。此間接證實了「奧卡姆剃刀原則」在大模型推論經濟學中的計量基礎—即「如無必要，勿增指令」。

圖 9 則更進一步從機率分布上解構了此現象，找出優化成功的效益區間為 Token 消耗數落在 1682 至 3874 之間，表示系統消耗過少或過多都較可能導致優化退化。這也間接證實了此區間之右側，可能由於提示詞已過度優化導致發散，從而使優化退化率較高，且實驗所設定最大優化迭代 2 次，可有效防止系統反覆觸發負反饋並陷入無效優化導致成本無限成長。

最終，圖 10 之成本效益象限圖為系統落地提供了決策建議。位於第一象限之混合策略具備最佳優化品質，適合面對未知的任務類型且不計較成本之應用場景；另外，位於第三象限最左側之角色扮演策略，能以最低 Token 開銷，換取近乎平均之優化水準，有著最高的策略投資性價比，適合低成本又想得到一定優化成效之應用場景。此一完整的結果光譜又再次實證了「奧卡姆剃刀原則」：在資源受限環境或特定任務情境下，使用簡潔、較低成本之單一策略(如角色扮演)，有著更高的性價比。

5.5 生成模型基底能力對優化效益之邊界效應探討

本實驗所採用之生成模型為輕量化的 GPT-4o-mini，若換成參數規模更龐大、基底能力更強大的模型來做一樣的實驗與分析，可能對於整體實驗結果會有影響，以下從模型天花板與提示詞敏感度雙重維度進行推論。

首先，在總體勝分差方面，由於高階模型在預訓練階段已具備極強的上下文理解力與指令遵循度，其面對使用者輸入之原始提示詞時，本身即能展現出極高水準之推理與寫作回應。這意味著，當自動改寫機制將其升級為優化提示詞後，系統所能挖掘之品質拉抬淨值將會被限縮，從而導致平均總體勝分差變低。換言之，自動提示工程對於基底能力較弱之模型具備「雪中送炭」之決定性增益；而對於高階強大模型，其邊際效益則更傾向於「錦上添花」。

其次，在四種優化策略之性價比與成本效益象限排名上，預期可能發生逆轉。在現行架

構下，混合策略因字數肥大，導致模型解碼時極易觸發注意力資源分散與「指令過度擁擠」之飽和失效。然而，高階模型可能因具備更為寬廣之語意長尾注意力分配能力，能完美駕馭多重、互斥的高難度約束。因此，若換成更好的生成模型，混合策略可能帶來更優秀的優化能力。反之，本系統之最高性價比之角色扮演策略，在高階模型中則可能面臨邊際效益急速劇降之風險。此因高階強大模型天生已具備深厚之零樣本擬真專家語氣能力，無需依靠外界強加複雜之身分設定。在此邊界條件下，堆砌角色扮演指令所帶來的 Token 消耗，可能將無法換取對等的品質躍升，使其不再為最高性價比之黃金策略。此一討論也表示自動提示優化策略之最優工程調度，本身可能也與生成模型基底能力高度動態綁定。

六、 結論及未來研究方向

本研究成功建構了一套基於元提示技術之提示詞自動優化系統，在工程架構上落實前後端分離設計，前端採用 Next.js 與 Tailwind CSS，後端則串接多模型 API 執行模組化控制流，以及設計根據負反饋錯誤軌跡之閉環迭代優化控制流，並設定最大迭代次數為 2 之工程保險絲，有效遏制了成本之無限膨脹。同時，為了解決開放式任務中單一模型評審所無法避免之系統性偏誤與字數偏誤，本研究採用異質 AI 評審團雙盲量化評估機制，大幅提升了實驗數據之客觀性與公信力。

在資料科學計量與大模型推論經濟學之實證上，本研究也進行了一些結果分析。透過皮爾森相關係數計量，本研究實證了真實營運總成本與五大品質提升量之間的相關係數均小於 0.1，呈現統計學上之微弱零相關，表示盲目增加改寫指令字數並不能保證生成品質之線性正向提升。同時，利用無母數核密度估計演算法，本研究推斷出系統之黃金營運效益區間，並深度論證了跨越飽和失效邊界後，因指令過度簡短與過度優化所觸發之退化風險。最終，藉由成本效益四象限，清晰量化出各策略之優化效益光譜，實證了奧卡姆剃刀原則在日常提示工程中的工程價值，表明在特定任務或資源受限環境下，簡潔、低成本之單一優化策略才是達成部署與成本效益最大化之最佳路徑。

儘管本系統在文字生成任務與推論經濟學計量上已取得階段性成果，但考量到生成式人工智慧技術之高速演進，本研究仍存在許多可進一步深化之工程探究。首先，多模態提示詞自動優化之跨域擴展為首要演進方向。由於目前系統範疇僅聚焦於大型語言模型之文字生成任務，暫不包含圖像、音樂或影片等多媒體生成之提示詞優化，未來研究可嘗試將元提示詞引擎進行跨模態改寫模板之適配性分析，以探明推論經濟學與成本效益在多模態部署中特徵性。其次，未來的自動化功能演進應朝向在後端控制流中加入輕量化之語意意圖分類器。現行系統仍仰賴使用者手動選定特定的優化策略，未來的完全體架構期望能僅憑使用者輸入之原始提示詞，由系統在後端自動將其歸類為特定日常任務類別，並根據本研究實證出之成本效益象限與適用性規律，自動動態路由至最適配且具備最高性價比之優化策略，達成全自動化之工程流調度。最後，應該如前一章節最後所推論之方向進行實驗，即更換成更高階之生成模型驗證其是否會對實驗結果，又是否會對各個優化策略的適配性與性價比產生大幅度影響。

七、 組員貢獻

本組組員只有我，因此所有研究皆由我一人獨自完成。

八、 參考文獻

[1] P. Sahoo, A. K. Singh, S. Saha, V. Jain, S. Mondal, and A. Chadha, "A systematic survey of prompt engineering in large language models: Techniques and applications," *arXiv preprint arXiv:2402.07927*, vol. 1, 2024.

[2] A. Kong *et al.*, "Better zero-shot reasoning with role-play prompting," in *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, 2024, pp. 4099–4113.

[3] L. Reynolds and K. McDonell, "Prompt programming for large language models: Beyond the few-shot paradigm," in *Extended abstracts of the 2021 CHI conference on human factors in computing systems*, 2021, pp. 1–7.

[4] J. Wei *et al.*, "Chain-of-Thought Prompting Elicits Reasoning in Large Language Models," in *Advances in Neural Information Processing Systems*, S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, Eds., Curran Associates, Inc., 2022, pp. 24824–24837.

[5] Y. Zhou *et al.*, "Large language models are human-level prompt engineers," in *The eleventh international conference on learning representations*, 2022.

[6] C. Yang *et al.*, "Large language models as optimizers," in *International Conference on Learning Representations*, 2024, pp. 12028–12068.

[7] L. Zheng *et al.*, "Judging llm-as-a-judge with mt-bench and chatbot arena," *Adv. Neural Inf. Process. Syst.*, vol. 36, pp. 46595–46623, 2023.

[8] P. Wang *et al.*, "Large language models are not fair evaluators," in *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 2024, pp. 9440–9450.

[9] C.-M. Chan *et al.*, "Chateval: Towards better llm-based evaluators through multi-agent debate," in *International conference on learning representations*, 2024, pp. 9079–9093.

[10] L. Chen, M. Zaharia, and J. Zou, "Frugalgpt: How to use large language models while reducing cost and improving performance," *arXiv preprint arXiv:2305.05176*, 2023.